

Machine Learning

Mini Research Project

과제명	국문	머신러닝 기반 항공권 가격 예측 및 좌석 등급별 요인 분석
	영문	Machine Learning-Based Flight Price Prediction and Feature Analysis by Class

조장: 김 민 서
조원: 김 예 린
이 소 민
이 예 빈
이 채 민

1. Introduction

1.1 연구의 배경

항공권 가격은 고정된 체계가 아닌 실시간 수요, 공급에 따라 지속적으로 변동하는 동적 가격 책정(dynamic pricing) 방식으로 운영된다. 항공사는 예약 시점, 좌석 잔여 수, 계절적 요인, 공휴일, 노선별 수요, 경쟁사의 가격 정책 등 다양한 변수를 실시간으로 반영하여 운임을 조정하며, 이는 수익 극대화를 위한 핵심 전략 수단으로 기능한다. 반면, 소비자 입장에서 이러한 가격 변동성은 정보의 비대칭성과 불확실성을 초래한다. 동일 노선과 좌석임에도 구매 시점에 따라 운임 격차가 크게 발생하며, 항공사는 예약률, 좌석 점유율과 수요 예측 데이터 등 소비자가 접근하기 어려운 내부 정보를 기반으로 가격을 결정하기 때문에 공급자와 소비자 간의 정보 비대칭이 존재한다. 이러한 배경에서 항공권 가격 예측 모델은 소비자에게는 합리적 구매 시점 판단을 지원하고, 항공 산업에는 가격 결정 요인 분석 및 시장 수요 이해에 활용될 수 있다는 점에서 연구적 가치를 지닌다.

1.2 기존 방법론의 한계점

기존 항공권 가격 예측 연구들은 세 가지 공통적인 방법론적 한계를 지닌다. 선형 회귀나 시계열 모델 등 전통적인 통계 기법은 구조적 특성상, 예약 시점, 수요, 경쟁 등 복합 요인에 의해 비선형적으로 급변하는 항공권 가격의 전 구간을 설명하는 데 한계가 있다 [2], [4], [9], [11]. [3], [6], [11]에서는 트리 기반 앙상블 모델이 대안으로 제시되었으나, 기존 연구들은 배깅(Bagging)과 부스팅(Boosting)을 각각 독립적으로 활용하였을 뿐 두 방식의 보완적 결합은 시도되지 않아 편향과 분산을 동시에 제어하는 데 여전히 한계가 있다[5]. 나아가 선행 연구의 대부분은 이코노미와 비즈니스 클래스 데이터를 통합하여 특성 중요도를 산출하였다. 그러나 두 등급은 가격의 절대적 가격 차이가 매우 클 뿐만 아니라, 가격 변동을 결정하는 지배적 요인 역시 상이하다 [2], [11]. 이처럼 메커니즘이 다른 두 클래스를 하나의 특성 중요도로 통합하여 해석할 경우, 특정 등급에 편향된 결과가 도출되거나 각 등급 고유의 변동 패턴이 상쇄되어 정확한 프라이싱 요인을 규명하기 어렵다. 이는 단순히 단일 최적 모델을 구축하는 것에 그치지 않고, 해당 모델 내에서 좌석 등급별 특성 중요도를 분리 추출하여 클래스별 가격 결정 요인을 비교해야 할 필요성을 시사한다.

1.3 연구 목적

본 연구는 다단계 분석 프레임워크를 통해 항공권 가격 예측의 정밀도와 해석 가능성을 동시에 향상시키는 것을 목적으로 한다. 우선, Ridge, Lasso, Multiple Linear Regression, Decision Tree(DT), Random Forest(RF), Extra Trees, Extreme Gradient Boosting(XGBoost), Light Gradient Boosting Machine(LightGBM), Categorical Boosting(CatBoost), k-Nearest Neighbors(KNN), Support Vector Machine(SVM)을 포함한 복수의 단일 모델 예측 성능을 체계적으로 비교한다. 이후, 단일 모델 중 가장 성능이 우수한 모델을 사용하여 특성 중요도를 추출한다. 이때, 분석 결과를 근거로 이코노미와 비즈니스 클래스의 독립된 중요도를 추출하여 비교한다. 마지막으로, 기존의 단일 모델들보다 우수한 성능을 낼 수 있는 스택킹 앙상블 모델을 구축한다. 배깅, 부스팅 기반 모델과 메타 러너(Meta-Learner)를 결합한 스택킹 앙상블(Stacking Ensemble) 프레임워크를 구축함으로써 예측 정밀도를 동시에 향상시키는 것이 본 연구의 목표이

다.

2. Related Work

2.1 선행 연구 소개

항공권 가격 예측 연구는 초기의 선형 통계 모델에서 출발하여 트리 기반 앙상블, 딥러닝, 그리고 모델 결합 기법으로 점진적인 발전이 이루어졌다. 선행 연구들에서 사용한 모델들을 크게 세 개의 방법으로 구분할 수 있다. 항공권 가격 예측 분야에서 먼저 시도된 접근은 변수 간 선형 관계를 가정하는 통계 모델이었다. Deng은 [2]에서 선형 회귀(LR), 의사결정 나무(DT), 랜덤 포레스트(RF)를 비교하며 좌석 등급(Class)이 항공권 가격과 상관관계수 -0.940 으로 가장 강한 연관성을 지닌 핵심 변수임을 확인하였다. 여기서 선형회귀(LR)은 R^2 Score 0.905, MAE 4,621.920에 그쳐 비선형적으로 급변하는 항공권 가격의 전 구간을 충분히 설명하지 못하는 한계를 드러냈다. Yu는 [11]에서도 동일 데이터셋을 활용하여 LR의 R^2 Score 0.905, MAE 4,630.300, MAPE 43.89%를 기록하며 해당 한계를 재확인하였다. Korkmaz는 [4]에서 이 한계를 보완하고자 SVM, 신경망, 가우시안 프로세스 회귀(GPR) 등 비선형 모델을 도입하였고, GPR이 가장 높은 성능을 나타냄을 확인하였다. Asukar와 Londhe는 [9]에서 ARIMA, SARIMAX, Holt-Winters 등 전통적인 시계열 모델을 인도 국내선 데이터에 적용하였으나, 이들 모델이 선형 가정과 고정된 계절성 구조에 의존하기 때문에 항공권 가격 특유의 불규칙한 급등락 구간을 포착하는 데에는 한계가 있음을 실증하였다. 비선형 문제에 대한 대안으로 트리 기반 앙상블 모델이 빠르게 주류 기법으로 부상하였다. Deng [2]에서 랜덤 포레스트(RF)가 R^2 Score 0.989, MAE 888.960으로 선형 모델과 단일 의사결정트리(DT)를 압도함이 확인되었으며, Yu [11]의 연구에서도 랜덤 포레스트(RF), XGBoost, 선형 회귀(LR)은 세 모델을 비교한 결과 RF가 R^2 Score 0.984, MAE 1,169.370, MAPE 7.9%로 XGBoost(R^2 0.977, MAPE 14.23%)와 선형회귀(LR)을 모두 상회하며 복잡한 비선형 데이터에서 랜덤 포레스트(RF)의 우수성이 입증되었다. Reddy 외는 [6]에서 방갈로르-콜카타 노선 데이터를 대상으로 LightGBM, XGBoost, SVR 등 6개 회귀 모델을 비교하여 부스팅 계열 모델이 선형 모델 대비 일관되게 높은 예측 성능을 확인하였다. Ertürk 외는 [3]에서 약 30만 건의 대규모 항공권 데이터에 XGBoost, LightGBM, CatBoost 등을 비교하였으며, XGBoost가 R^2 Score 0.980, MAE 2,035.510로 최고 성능을 달성함으로써 대용량 환경에서 부스팅 계열의 유효성을 입증하였다. Asukar와 Londhe [9]의 연구에서도 LightGBM이 R^2 Score 0.894으로 ARIMA(R^2 Score 0.101), LSTM(R^2 0.083) 등 모든 비교 모델을 상회하여 계절성이 강한 시계열 데이터 환경에서도 앙상블 계열의 우수성이 재확인되었다. 트리 기반 앙상블 기법이 성숙됨에 따라 일부 연구는 딥러닝 기반 접근으로 연구 방향을 전환하였다. Degife와 Lin은 [7]에서 44개의 피처를 입력으로 하는 게이트 순환 유닛(GRU) 모델을 제안하였으며, MAE, RMSE, R^2 Score 모든 지표에서 기존 머신러닝 모델과 LSTM, MLP를 넘어서는 성능을 달성하였다. Kalampokas 외는 [1]에서 랜덤 포레스트(RF)와 그래디언트 부스팅을 포함한 앙상블 모델, 딥러닝(Deep Learning), 양자 머신러닝(QML) 등 총 16개 아키텍처를 비교한 결과, 딥러닝 및 양자 모델이 89~99% 범위의 최고 정확도를 달성함을 확인하였다. Dhanush 외는 [10]에서 한층 더 나아가 21개 모델을 단일 프로토콜 하에 비교하였으며, TabTransformer가 R^2 Score 0.995, MAPE 3.41%로 전체 1위를 차지하였고 트리 기반인 ExtraTrees(R^2 Score=0.992)가 그 뒤를 이었다. 이 연구는 딥러닝 기반 Transformer 구조가 피

처 간 상호작용을 명시적으로 모델링함으로써 트리 앙상블 모델로는 포착하기 어려운 복잡한 가격 결정 패턴을 포착할 수 있음을 보여준다. Chavan 외는 [5]에서 랜덤 포레스트(RF)와 그래디언트 부스팅으로 R^2 Score 0.90~0.92를 달성하면서도, 개별 앙상블 모델의 한계를 극복하기 위한 스택킹(Stacking) 모델 도입을 후속 과제로 제안하였다. Wong 외는 [8]에서 약 2,000만 건의 Expedia 데이터를 Apache Spark 환경에서 처리하여 그래디언트 부스트 트리가 R^2 Score 0.706으로 가장 높은 성능을 보였다.

2.2 선행 연구의 한계점 및 시사점

앞서 검토한 선행 연구를 종합하면 기존 항공권 가격 예측 연구는 데이터 분석 및 모델링 아키텍처 측면에서 몇 가지 명확한 한계점과 시사점을 남긴다. 우선, 예약 시점, 잔여 좌석, 수요 및 경쟁 상황 등이 복합적으로 작용하는 항공권 가격의 비선형성을 전통적인 통계 기법으로 포착하는 데는 명확한 한계가 있음이 실증적으로 증명되었다. Asukar와 Londhe [9]의 실험에서 시계열 모델인 ARIMA와 SARIMAX는 R^2 Score가 0.100 수준에 머무른 반면, 머신러닝 기반의 LightGBM은 R^2 Score가 0.890의 높은 예측력을 기록하였다. 또한 Yu [11]의 연구에서도 선형 회귀 모델의 오차(MAPE)가 43.89%에 달해 급격한 가격 변동 구간을 제대로 반영하지 못함을 보여주었다. 이러한 한계는 향후 항공권 가격 예측 모델을 구축할 때 복잡한 파라미터 간의 상호작용을 학습할 수 있는 비선형 머신러닝 모델의 도입이 필수적임을 시사한다. 이러한 모델링 차원의 정교화 요구와 더불어, 기존 연구들은 좌석 등급별 데이터의 이질성을 간과한 채 단일 모델을 적용함으로써 특정 데이터에 치우친 예측 결과를 도출하는 한계를 보였다. Deng [2]의 연구에 따르면 좌석 등급과 가격 간의 상관관계는 -0.940으로 매우 높게 나타났음에도 불구하고, 분석 대상이 된 선행 연구들은 이코노미와 비즈니스 클래스 데이터를 분리하지 않고 하나의 모델로 통합하여 학습했다. 특히 전체 데이터의 약 80%가 이코노미 클래스에 집중되어 있던 Yu [11]의 연구 구조에서는 표본 수가 상대적으로 적은 비즈니스 클래스 고유의 가격 결정 메커니즘이 학습 과정에서 희석될 위험이 크다. 이는 단순히 등급을 하나의 통제 변수로 투입하는 방식을 넘어 좌석 등급별로 데이터를 분할하거나 특성 중요도(Feature Importance)를 독립적으로 산출하여 클래스별 프라이싱 요인을 다각적으로 규명해야 할 필요성을 뒷받침한다. 이처럼 데이터 분석 단위의 불균형뿐만 아니라, 알고리즘 자체를 결합하고 고도화하는 측면에서도 미해결 과제가 존재한다. 최근 연구들이 트리 기반 앙상블 모델을 대안으로 제시하고 있음에도 불구하고, 여전히 개별 알고리즘의 단일 활용에 그치고 있다는 점이다. 배깅(Bagging) 기반 모델은 분산(Variance) 감소에, 부스팅(Boosting) 기반 모델은 편향(Bias) 감소에 강점을 지니는 상호 보완적 특성이 있으나 기존 연구들은 두 기법의 유기적 결합을 시도하지 않았다. 실제로 Yu [11]의 연구는 랜덤 포레스트와 XGBoost를 독립적으로 비교하는 선에 머물렀고, Dhanush 외 [10] 역시 21개의 모델을 비교하면서도 모델 결합 가능성은 검토하지 않았다. 결과적으로 Chavan 외 [5]가 후속 과제로 스택킹(Stacking) 모델 도입을 명시적으로 제안했음에도 선행 연구에서 다루지지 않은 이 공백은, 향후 배깅과 부스팅의 강점을 결합한 앙상블 아키텍처 설계가 수행되어야 함을 시사한다.

2.3 본 연구의 차별성

선행 연구의 한계를 기반으로 본 연구는 두 가지 방향으로 기존 접근을 발전시킨다. 본 연구는 배깅과 부스팅의 장점을 결합한 스택킹 앙상블(Stacking Ensemble) 프레임워크를 구축하여 예측

성능을 향상시킨다. Chavan 외 [5]가 스택킹 도입을 제안하였고, Dhanush 외 [10]의 연구에서 21개 모델이 단독으로만 비교되었던 점에 착안하여, 본 연구는 Yu [11] 등 기존 선행 연구들에서 검증된 랜덤 포레스트, XGBoost, LightGBM에 더하여 KNN, CatBoost, SVM, Decision Tree, Extra Trees를 스택킹의 베이스 러너(Base Learner) 후보군으로 확장한다. 이를 통해 단일 알고리즘에 의존하는 기존 구조의 한계를 극복하고, 다양한 학습 방식의 모델들의 1차 예측값을 Ridge 회귀 메타 러너가 최적으로 결합하는 구조를 통해 예측 안정성과 일반화 성능을 향상시킨다. 또한, 단순한 성능 수치 비교를 넘어, 특성 중요도 분석을 통해 등급별 가격 결정 핵심 변수를 해석적으로 제시한다. Degife와 Lin [7] 및 Dhanush 외 [10]의 연구에서 높은 예측 성능에도 모델 해석 가능성이 확보되지 못한 한계를 보완하여, 본 연구는 예측 성능과 해석력을 함께 갖춘 분석 프레임워크를 제시한다.

3. Proposed Method

3.1 연구 프레임워크

본 연구는 다국적 항공권 데이터를 활용하여 가격을 정밀하게 예측하고, 운임 변동에 미치는 핵심 요인을 규명하기 위한 기계학습 기반의 파이프라인 프레임워크를 제안한다. 제안하는 전체 분석 파이프라인의 흐름은 그림 1과 같으며, 구체적으로 다음과 같은 네 가지 단계를 거쳐 수행된다.




그림 1 연구 프레임워크

첫 번째 단계(Data Ingestion)는 데이터의 수집 및 화폐 단위 통합 과정이다. 인도와 방글라데시의 오픈 소스 항공권 데이터세트를 취합한 후, 상이한 국가에서 수집됨에 따라 발생하는 화폐적 왜곡을 방지하고자 당일 기준 환율을 반영하여 통화 단위를 인도 루피(INR)로 일원화하였다. 두 번째 단계(Data Preparation & Feature Engineering)는 데이터의 품질 고도화 및 변수 최적화 과

정이다. 결측치를 제거한 후, 가격 변수의 비대칭적 분포를 완화하여 통계적 수렴 속도를 높이고자 타겟 변수인 가격에 로그 변환을 적용하였다. 아울러 도메인 지식을 기반으로 파생 변수를 생성하고, 원-핫 인코딩과 표준화 스케일링을 거쳐 정제된 학습 데이터를 구축하였다. 세 번째 단계(Model Training & Optimization)는 머신러닝 알고리즘의 학습 및 앙상블 아키텍처 설계 과정이다. 다중 선형 회귀(Multiple Linear Regression), 릿지(Ridge), 라쏘(Lasso)와 비선형 구조 포착을 위해 트리 기반 모형과 그래디언트 부스팅과 더불어 SVM(Support Vector Machine)과 KNN(k-Nearest Neighbors) 알고리즘을 도입한다. 각 모델은 하이퍼파라미터 튜닝을 통해 최적화되었으며, 최종적으로 개별 알고리즘의 이점을 결합하여 예측 성능을 극대화한 스택킹 앙상블(Stacking Ensemble) 모델을 구축하였다. 마지막 네 번째 단계(Model Evaluation & Insights)는 모델의 성능 검증 및 사후 분리 분석 과정이다. MAE, RMSE, R^2 Score 지표를 통해 정량적 예측 정밀도를 평가한 후, 복잡한 스택킹 모형이 지닌 블랙박스(Black Box) 한계를 보완하기 위해 해석 가능성이 가장 우수한 알고리즘으로부터 특성 중요도를 추출하였다. 이를 바탕으로 전체 데이터를 이코노미와 비즈니스 클래스를 분리 분석함으로써 좌석 등급별 차별화된 가격 결정 핵심 요인을 확인하고자 한다.

3.2 Baseline Model

본 연구에서 제안하는 앙상블 모델의 성능 개선 효과를 검증하기 위해, Multiple Linear Regression, Ridge, Lasso, Decision Tree(DT), Random Forest(RF), Extra Trees, Extreme Gradient Boosting(XGBoost), Light Gradient Boosting Machine(LightGBM), Categorical Boosting(CatBoost), k-Nearest Neighbors(KNN), Support Vector Machine(SVM)를 베이스라인 모델로 설정하였다. 전통적인 선형 회귀 기반 모델들은 변수 간의 관계를 직관적으로 해석하기 용이하지만, 항공권 가격처럼 수요와 예매 시기에 따라 비선형적이고 급격하게 변하는 다이내믹 프라이싱(Dynamic Pricing) 패턴을 정교하게 학습하는 데에는 한계가 있다. 반면, 의사결정나무(Decision Tree)나 랜덤 포레스트(Random Forest) 같은 단일 트리 기반 모델은 복잡한 데이터 패턴은 잘 포착하지만 특정 데이터에 과적합(Overfitting)될 위험이 존재한다. 따라서 본 연구에서는 개별 모델들의 단점을 상호 보완할 수 있는 새로운 접근 방식을 제안한다.

3.3 Baseline 대비 개선 아이디어 및 변경

기존 단일 모형의 한계를 극복하고 예측의 정확도 향상과 사후 설명력을 확보하기 위해, 본 연구는 특성 공학, 스택킹 앙상블 구축, 그리고 사후 분리 분석으로 이어지는 체계적인 방법론을 제안한다. 먼저, 데이터의 비대칭성을 완화하고 시간적 맥락을 반영하기 위한 특성 공학(Feature Engineering)을 수행한다. 항공권 가격 데이터는 극단적인 고가 운임이 포함되어 있어 우측으로 꼬리가 긴 비대칭(Right-skewed) 분포를 띠는 경향이 있다. 이를 해결하기 위해 종속변수인 가격에 로그 변환을 적용하여 분포를 정규화하였다. 또, 출발 전 남은 일수(days_left)를 3개의 구간으로 범주화한 '예약 기간(booking_period)' 변수를 추가 생성함으로써, 출발일이 임박할수록 가격이 급등하는 패턴을 모델이 명확하게 학습할 수 있도록 전처리 구조를 확립하였다. 이와 같이 정제된 데이터를 바탕으로 스택킹 앙상블(Stacking Ensemble)을 구축한다(그림 2). 단일 모델이 가질 수 있는 예측 편향을 방지하기 위해 작동 방식이 서로 다르고 성능이 우수한 4개의 알고리즘들(Random Forest, Ridge, LightGBM, CatBoost)을 1차 기반 모델(Base Learner)로 학습시킨다.

이후 각 모델이 예측한 결과값들을 새로운 변수로 취합하고, 규제를 위해 릿지(Ridge) 회귀를 모델 (Meta Learner)로 사용하여 최종 가격을 산출한다. 여러 알고리즘의 예측 강점을 종합하는 이 방식을 통해 단일 모델 대비 예측의 안정성과 정확도를 대폭 개선하고자 한다. 최종적으로는 정교한 예측을 넘어 가격 변동의 핵심 요인을 도출하고자 사후 분리 분석을 진행한다. 스택킹 앙상블을 구성하는 모델 중 가장 예측 성능이 우수했던 랜덤 포레스트(Random Forest) 알고리즘의 특성 중요도(Feature Importance)를 추출하여 가격 결정 요인을 정량적으로 분석한다. 이때 가격 결정에 가장 큰 기여를 하는 변수인 '좌석 등급(Class)'을 기준으로 전체 데이터를 이코노미와 비즈니스 클래스로 분리한다. 분리된 각 클래스 내부에서 예매 시점, 비행 소요 시간 등의 세부 요인들이 가격에 미치는 영향력을 심층적으로 비교 분석함으로써 연구의 설명력을 높인다.




그림 2 스택킹 앙상블 파이프라인

4. Experiment & Evaluation

4.1 Dataset

본 연구에서는 항공권 가격 예측 모델의 성능을 평가하기 위하여 두 개의 공개 데이터세트를 활용하였다. 캐글(Kaggle)에서 제공되는 1)'Flight Price Prediction' 데이터셋(Clean_Dataset.csv)로, 실제 항공권 예약 플랫폼에서 수집된 인도 국내선 항공권 정보를 포함하고 있으며 약 300,153건의 레코드와 11개 변수로 구성된다(표1). 또한, 캐글에서 제공되는 2)'Flight Price Dataset of Bangladesh'(Flight_Price_Dataset_of_Bangladesh.csv) 방글라데시 국내외 노선의 항공권 정보를 포함하며 57,000건의 레코드와 17개 변수로 구성된 데이터를 사용하였다(표2). 두 데이터셋의 공통 변수를 기준으로 병합해 전처리 후 최종적으로 338,174건의 최종 데이터세트를 구성하였다(표3).

1) Bathwal, S. (2022). Flight Price Prediction. Kaggle.

<https://www.kaggle.com/datasets/shubhambathwal/flight-price-prediction>

2) Tusher, M. (2025). Flight Price Dataset of Bangladesh. Kaggle.

<https://www.kaggle.com/datasets/mahatiratusher/flight-price-dataset-of-bangladesh>

표 1. 인도 데이터세트 (300,153행 / 11개 변수)

변수명	자료형	값의 범위 / 고유값	설명
airline	문자형	인도 5개사, 방글라데시 24개사	운항 항공사명
route	문자형	인도 29개 노선, 방글라데시 출발·도착 조합	출발·도착 도시를 결합한 노선 식별 변수
stops	정수형	0, 1, 2 (회)	비행 중 경유 횟수
departure_time	문자형	Early Morning / Morning / Evening / Night / Late Night	출발 시간대
arrival_time	문자형	Early Morning / Morning / Evening / Night / Late Night	도착 시간대
class	문자형	Economy / Business	항공권 좌석 등급
duration	실수형	0.50 ~ 49.83 (hrs)	총 비행 소요 시간
days_left	정수형	1 ~ 90 (일)	탑승일 기준 예약까지 남은 일수
booking_period	문자형	단기(8~21일 전) / 장기(22일 이상)	days_left를 구간화한 예약 시점 변수
country (파생)	문자형	India / Bangladesh	데이터 출처 국가, 통합 시 수동 부여
price	실수형	1,106 ~ 123,072 (INR)	항공권 가격, 방글라데시는 BDT→INR 환산, 로그변환 적용

표 2. 방글라데시 데이터세트 (57,000행 / 17개 변수)

변수명	자료형	값의 범위/고유값	설명
Airline	문자형	24개 항공사 (Malaysian Airlines 등)	항공사명
Source	문자형	8개 공항 코드 (CXB, BZL 등)	출발 공항 코드
SourceName	문자형	8개 공항명 (Cox's Bazar Airport 등)	출발 공항명
Destination	문자형	20개 공항 코드 (CCU, CGP 등)	도착 공항 코드
Destination Name	문자형	20개 공항명 (Kuala Lumpur Intl 등)	도착 공항명
Departure Date & Time	문자형	54,126개 고유값	출발 일시
Arrival Date & Time	문자형	56,944개 고유값	도착 일시
Duration (hrs)	실수형	0.50 ~ 15.83 (시간)	총 비행 소요 시간
Stopovers	문자형	Direct, 1 Stop, 2 Stops (3종)	비행 중 경유 횟수
Aircraft	문자형	Airbus A320, Boeing 787 등 (5종)	항공기 기종
Class	문자형	Economy, Business, First Class (3종)	항공권 좌석 등급
Booking Source	문자형	Online Website, Travel Agency 등 (3종)	예약 경로
Base Fare (BDT)	실수형	1,600.98 ~ 449,222.93 BDT	기본 운임 (방글라데시 타카)
Tax & Surcharge (BDT)	실수형	200.00 ~ 73,383.44 BDT	세금 및 할증료

Total Fare (BDT)	실수형	1,800.98 ~ 558,987.33 BDT	총 항공권 가격 (목표변수)
Seasonality	문자형	Regular, Winter Holidays 등 (4종)	계절성 / 성수기 구분
Days Before Departure	정수형	1 ~ 90 (일)	출발까지 남은 일수

표 3. 통합 데이터셋(338,174행 / 11개 변수)

변수명	자료형	값의 범위/고유값	설명
airline	문자형	인도 5개사, 방글라데시 24개사	운항 항공사명
route (파생)	문자형	인도 29개 노선, 방글라데시 출발·도착 조합	출발·도착 도시를 결합한 노선 식별 변수
stops	정수형	0, 1, 2 (회)	비행 중 경유 횟수
departure_time (부분파생)	문자형	Early Morning / Morning / Evening / Night / Late Night	출발 시간대
arrival_time (부분파생)	문자형	Early Morning / Morning / Evening / Night / Late Night	도착 시간대
class	문자형	Economy / Business	항공권 좌석 등급
duration	실수형	0.50 ~ 49.83 (hrs)	총 비행 소요 시간
days_left	정수형	1 ~ 90 (일)	탑승일 기준 예약까지 남은 일수
booking_period (파생)	문자형	단기(8~21일 전) / 장기(22일 이상)	days_left를 구간화한 예약 시점 변수
country (파생)	문자형	India / Bangladesh	데이터 출처 국가, 통합 시 수동 부여
price (종속변수, 부분파생)	실수형	1,106 ~ 123,072 (INR)	항공권 가격. 방글라데시는 BDT→INR 환산, 로그변환 적용

4.2 Baseline Method

본 연구에서 제안하는 항공권 가격 예측 모델의 성능을 객관적으로 평가하기 위해, 선형 회귀, 거리 기반 및 초평면 기반의 머신러닝, 그리고 트리 앙상블 및 부스팅 계열 등 총 11개를 베이스라인 모델로 하였다. 공정한 성능 비교 실험을 위하여 모든 모델은 동일한 학습 및 테스트 데이터 세트 조건에서 독립적으로 학습되었으며, 최적의 예측 성능을 도출하기 위해 Grid Search 및 Randomized Search를 수행하여 하이퍼파라미터를 최적화하였다. 각 베이스라인 모델별 주요 하이퍼파라미터 명칭과 실험을 통해 도출된 최종 최적 설정값 및 기술적 서술은 표4와 같다.

표 4. 분석 모델별 하이퍼파라미터 설정 및 기술적 특징

모델 (Model)	하이퍼파라미터 (Hyperparameter)	기술적 설명 (Description)
Multiple Linear Regression	None	변수 간의 가장 기본적인 선형 관계를 파악하고 최소 성능 기준점을 제공한다.
Ridge Regression	alpha=10	L2 규제를 적용하여 가중치 왜곡을 억제하고 일반화 성능을 확보한다.
Lasso Regression	alpha=0.0001	L1 규제를 통해 불필요한 변수의 가중치를 0으로 조정하여 변수를 선택한다.
K-Nearest	n_neighbors=8, weights=distance, p=2	거리 유사성을 기반으로 하며, 인접한

Neighbors Regressor (KNN)		데이터에 가중치를 부여하여 예측 정확도를 제어한다.
Support Vector Machine (SVM)	C=0.1, epsilon=0.1, max_iter=10000, tol=1e-3	선형 회귀 초평면을 탐색하며, 오차 허용 한계와 오차 가중치를 설정하여 대규모 데이터 학습의 안정성을 확보한다.
Decision Tree Regressor	max_depth=None, min_samples_split=10, min_samples_leaf=4	트리의 최대 깊이와 분할 조건을 제한하여 모델의 과적합을 방지한다.
Random Forest Regressor	n_estimators=100, max_depth=None, min_samples_split=10, min_samples_leaf=2, max_features='sqrt',	다수의 독립적인 의사결정나무를 결합하여 개별 모델이 가진 예측 분산을 감소시킨다.
Extra Trees Regressor	n_estimators=100, max_depth=10, min_samples_split=2, min_samples_leaf=1, max_features='sqrt',	노드 분할점을 무작위로 선택하여 과대적합을 방지하고 연산 속도를 개선한다.
Extreme Gradient Boosting (XGBoost)	n_estimators=148, learning_rate=0.1097, max_depth=6, min_child_weight=1, subsample=0.7140, colsample_bytree=0.7550, reg_alpha=0.5248, reg_lambda=2.2994, gamma=0.3042	잔차(Residual)를 순차적으로 보정하며, 다각적인 구조적 규제를 통해 과적합을 제어한다.
Light Gradient Boosting Machine (LightGBM)	n_estimators=245, learning_rate=0.1179, max_depth=7, num_leaves=45, min_child_samples=72, subsample=0.9707, colsample_bytree=0.6832, reg_alpha=0.4498, reg_lambda=2.2782	리프 노드 중심 성장을 통해 대규모 데이터의 미세한 변동 패턴을 수렴한다.
Categorical Boosting(CatBoost)	iterations=986, learning_rate=0.0827, depth=9, l2_leaf_reg=6.5655, border_count=221, bagging_temperature=0.3664, random_strength=0.9832	대칭 트리 구조를 기반으로 하며 복잡한 범주형 변수 환경에서 일반화 성능을 확보한다.

본 연구에서 설정한 베이스라인 모델들의 선정 근거는 다음과 같다. 선형 회귀 모델(Linear Regression, Ridge, Lasso)은 데이터 내 변수 간의 기본적인 선형적 인과관계를 파악하고 예측 성능의 기초적인 기준점을 확립하기 위해 포함되었다. 그 중, Ridge와 Lasso는 각각 L2 규제와 L1 규제를 적용하여 과적합을 완화하는 역할을 한다. 데이터 간의 거리를 측정하는 KNN과 경계면을 기준으로 분류 및 회귀를 수행하는 SVM은 독립적인 예측 알고리즘으로서 어느 정도의 성능 강점을 나타내는지 대조하기 위함이다. Decision Tree를 비롯하여 Random Forest와 Extra Trees 등의 트리 양상블 계열은 변수 간의 복잡한 비선형적 패턴과 대용량 데이터세트에서의 일반화 성능을 확인하기 위해 선정되었다. 마지막으로 그래디언트 부스팅 계열(XGBoost, LightGBM, CatBoost)은 본 연구의 핵심 비교 대상으로서, 대규모 정형 데이터 세트에서 높은 예측 정확도를 내는 알고리즘들인 만큼 잔차(Residual) 보정과 각 모델 고유의 규제 메커니즘이 항공권 가격 데이터세트에서 실제로 어느 정도의 성능 차이를 도출하는지 정밀하게 대조하기 위해 베이스라인으로 최종 채택하였다.

4.3 Evaluation Metrics

본 연구에서 제안하는 모델 및 베이스라인 모델들과 스택킹 모델의 성능을 정량적으로 평가하고

대조하기 위해 세 가지 지표인 Mean Absolute Error (MAE), Root Mean Squared Error (RMSE)와 Coefficient of Determination (R^2 Score)를 평가지표로 채택하였다. 각 평가지표의 정의 및 수학적식은 다음과 같다.

MAE는 실제 가격과 예측 가격 간의 절대적 오차를 평균한 값으로, 이상치(Outlier)의 영향에 비교적 강건하여 직관적인 오차 규모를 파악하는 데 유용하며, 식(1)과 같다.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (1)$$

RMSE는 오차의 제곱을 평균한 뒤 제곱근을 씌운 값이다. 오차가 커질수록 패널티를 크게 부여하는 특성이 있어, 급격한 변동이나 큰 오차를 얼마나 안정적으로 제어하는지 평가하는 지표로 활용되며, 식(2)와 같다.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2)$$

R^2 Score는 전체 데이터의 분산 중 모델이 독립변수를 통해 설명할 수 있는 분산의 비율이다. 1에 가까울수록 모델의 전체적인 설명력이 우수한 것으로, 모델 간의 전반적인 성능을 비교하는 지표가 되며, 식(3)과 같다.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3)$$

또한, 본 연구에서 활용한 두 데이터세트의 화폐 단위를 일치시키기 위해 기준 통화를 인도 루피(Rupee)로 통일하여 실험을 진행하였다. 데이터 전처리 과정에서는 가격 데이터의 왜도(Skewness)를 완화하기 위해 로그 변환(Log Transformation)을 적용하였으나, 최종 평가 단계에서는 예측 오차 범위를 직관적으로 파악할 수 있도록 지수 변환(Exponential Transformation)을 통해 원래의 인도 화폐 단위인 루피(Rupee)로도 복원하여 평가지표를 산출하였다.

4.4 Experimental Setup

본 연구는 Python 3.13.9 기반의 JupyterLab 환경에서 수행되었으며, 데이터 처리 및 모델 구현은 Pandas 2.3.3, NumPy, 그리고 scikit-learn 1.7.2 라이브러리로 진행하였다. 대규모 정형 데이터의 효율적인 처리를 위해 Pandas와 NumPy를 활용하였으며, 머신러닝 파이프라인 구성 및 성능 검증에는 scikit-learn을 사용하였다. 또한, 데이터 내 복잡한 비선형 패턴 학습 및 최종 예측 성능 향상을 위해 그래디언트 부스팅(Gradient Boosting) 기반 프레임워크인 XGBoost 3.2.0, LightGBM 4.6.0, 그리고 CatBoost 1.2.10을 추가적으로 도입하였다.

모델 학습을 위한 데이터 전처리 파이프라인은 다음과 같이 구성되었다. 먼저, 인도와 방글라데시에서 수집된 두 이종 데이터셋을 병합하는 과정에서 종속변수인 가격(price)의 통화 단위를 인도 루피(INR, 1BDT = 0.76INR)로 일치시켰다. 분석 목적에 맞추어 이코노미와 비즈니스 클래스에 해당하지 않는 데이터와 결측치가 포함된 행을 배제하였다. 이후 출발지와 도착지 정보를 결합한 노선(route) 변수와 출처 국가(country) 파생 변수를 생성하였으며, 예약 시점의 맥락을 반영하기 위해 출발 전 남은 일수(days_left)를 세 구간(0~7일, 8~21일, 22일 이상)으로 범주화하여 예약 기간(booking_period) 변수를 도출하였다. 특히, 항공권 가격 데이터 특유의 우측 꼬리가 긴 비대칭(Right-skewed) 분포를 정규 분포에 근사시키기 위해 종속변수에 로그 변환($\log(1+x)$)을 적용하였다. 이를 통해 이상치(Outlier)에 의해 모델의 학습이 왜곡되는 현상을 방지하고, 오차에 대한 민감도를 줄였다. 데이터 내의 범주형 변수는 그 성질에 따라 두 가지 방식으로 나누어 전처리를 수행하였다. 계층적 서열이 존재하는 횡수(stops)와 예약 기간(booking_period) 등의 순서형(Ordinal) 변수는 정수형으로 매핑하였다. 이와 달리 서열 관계가 없는 항공사, 좌석 등급, 노선 등 명목형(Nominal) 변수에는 원-핫 인코딩(One-Hot Encoding)을 적용하였다. 이때 생성된 더미 변수 간의 정보가 완벽히 중복되어 발생하는 '가변수 함정(Dummy Variable Trap)'과 이로 인한 다중공선성(Multicollinearity) 문제를 방지하고자, 각 변수의 첫 번째 범주를 독립 변수에서 제외하는 방식(drop_first=True)을 채택하였다. 전처리가 완료된 데이터는 학습 데이터(Training Data)와 테스트 데이터(Test Data)로 8:2 무작위 분할하였다. 이후 실전 배포 환경에서의 변수 불일치 오류를 예방하기 위해 테스트 데이터의 특성 배열을 학습 데이터 구조에 맞추어 재정렬(Reindexing)하였으며, 연속형 독립변수들은 표준화 스케일러(StandardScaler)를 사용해 일반화 성능 검증 시 발생할 수 있는 데이터 누수(Data Leakage)를 차단하였다.

각 베이스라인 모델의 최적 하이퍼파라미터 도출을 위해 모델별 특성에 맞춰 Grid Search를 사용하고 부스팅 계열의 알고리즘에는 Randomized Search 기법을 적용하였으며, k-fold Cross-Validation을 이용하여 평가의 객관성과 일반화 성능을 확보하였다. 본 연구에서 성능 비교 및 앙상블 학습을 위해 구축한 총 11개 베이스라인 모델의 세부적인 하이퍼파라미터 설정은 표 5와 같다. 각 모델의 과적합을 방지하고 예측력을 극대화하기 위해 설정한 하이퍼파라미터별 탐색 범위(Search Range)와 데이터 타입(Integer, Continuous)을 명시하였으며, 모델별 최적 설정값은 앞서 제시한 표 4에 상세히 기술하였다.

표 5. 모델별 하이퍼파라미터 탐색 범위 및 교차 검증 설정

Model	Search Range	Cross-Validation
Multiple Linear Regression	-	-
Ridge Regression	alpha=[0.001, 0.01, 0.1, 0.5, 1, 5, 10, 50, 100, 500, 1000]	k=3
Lasso Regression	alpha=[0.0001, 0.001, 0.01, 0.05, 0.1, 1.0]	k=3
K-Nearest Neighbors Regressor (KNN)	n_neighbors=[3, 5, 7, 9, 11] weights=['uniform', 'distance'] p=[1, 2] leaf_size=[20, 30, 40]	k=3
Support Vector Machine (SVM)	C=[0.1, 1.0] epsilon=[0.1]	k=2

Decision Tree Regressor	max_depth=[5, 10, 15, 20, Unlimited] min_samples_split=[2, 5, 10] min_samples_leaf=[1, 2, 4]	k=3
Random Forest Regressor	n_estimators=[100, 200, 300] max_depth=[10, 15, 20, Unlimited] min_samples_split=[2, 5, 10] min_samples_leaf=[1, 2, 4] max_features=['sqrt', 'log2']	k=3
Extra Trees Regressor	n_estimators=[100, 200] max_depth=[10, 15] min_samples_split=[2, 5] min_samples_leaf=[1, 2] max_features=['sqrt']	k=3
Extreme Gradient Boosting (XGBoost)	n_estimators=[100, 300] (Integer) learning_rate=[0.01, 0.20] (Continuous) max_depth=[3, 6] (Integer) min_child_weight=[1, 5] (Integer) subsample=[0.7, 1.0] (Continuous) colsample_bytree=[0.7, 1.0] (Continuous) reg_alpha=[0, 1] (Continuous) reg_lambda=[0.5, 5.0] (Continuous) gamma=[0, 1] (Continuous)	k=3
Light Gradient Boosting Machine (LightGBM)	n_estimators=[100, 300] (Integer) learning_rate=[0.01, 0.20] (Continuous) max_depth=[3, 8] (Integer) num_leaves=[20, 80] (Integer) min_child_samples=[10, 100] (Integer) subsample=[0.6, 1.0] (Continuous) colsample_bytree=[0.6, 1.0] (Continuous) reg_alpha=[0, 1] (Continuous) reg_lambda=[0.5, 5.0] (Continuous)	k=3
Categorical Boosting(CatBoost)	iterations=[300, 1000] (Integer) learning_rate=[0.01, 0.20] (Continuous) depth=[4, 10] (Integer) l2_leaf_reg=[1, 10] (Continuous) bagging_temperature=[0, 1] (Continuous) random_strength=[0, 1] (Continuous) border_count=[32, 255] (Integer)	k=3
Stacking Ensemble	estimators=base_models, final_estimator=meta_model, n_jobs=-1	k=3

선형 회귀 계열인 릿지(Ridge)와 라쏘(Lasso) 회귀 모형에서는 모델의 복잡도를 제어하는 규제 강도 매개변수(alpha)를 최적화하였다. 릿지 회귀의 경우 0.001부터 1000까지의 탐색 범위 중 가중치의 왜곡을 억제하고 일반화 성능을 가장 안정적으로 확보하는 alpha=10을 최종 채택하여 L2 규제를 적용하였다. 라쏘 회귀는 0.0001부터 1.0 사이의 범위에서 탐색을 진행하여 불필요한 변수의 가중치를 0으로 조정함으로써 자동 변수 선택 기능을 수행하는 최적의 L1 규제 강도로 alpha=0.0001을 도출하였다. 거리 기반 알고리즘인 K-최근접 이웃(KNN) 회귀 모형은 유클리드 거리 지표(p=2) 조건하에 이웃의 수(n_neighbors)를 3에서 11까지 탐색한 결과 최적의 성능을 보인 8로 확정하였으며, 인접 데이터와의 거리에 반비례하여 가중치를 부여하는 weights='distance' 기법을 적용하였다. 서포트벡터머신(SVM)은 계산 복잡도를 고려해 페널티 파라미터(C)와 허용 오차 한계(epsilon)의 탐색을 수행하여 최종적으로 C=0.1, epsilon=0.1을 도출하였다. 의사결정나무(Decision Tree) 및 트리 기반 앙상블 모형에서는 트리의 무제한적인 성장을 억제하여 과적합을

방지하는 파라미터 튜닝에 집중하였다. Decision Tree와 Random Forest 모형 모두 노드 분할을 위한 최소 샘플 수(min_samples_split)와 리프 노드가 되기 위한 최소 샘플 수(min_samples_leaf)의 후보군을 탐색하였으며, 최종적으로 min_samples_split=10과 각각 min_samples_leaf=4 및 2를 도출하여 복잡도를 제어하였다. 특히 Random Forest와 Extra Trees 모형은 개별 의사결정나무의 독립성과 다양성을 극대화하기 위해 무작위 특성 선택 비율을 전체 변수의 제곱근 수준인 max_features='sqrt'로 일치시켜 예측 분산을 감소시켰다. 최종 성능 고도화를 위해 도입된 그래디언트 부스팅 계열(XGBoost, LightGBM, CatBoost) 모형은 연속형 및 정수형 하이퍼파라미터 탐색 공간 내에서 정밀한 튜닝을 진행하였다. XGBoost는 잔차(Residual)의 순차적 보정과 구조적 규제를 위해 학습률을 learning_rate=0.1097, 트리 깊이를 max_depth=6, 트리 개수를 n_estimators=148로 최적화하였으며, L1 및 L2 규제 파라미터(reg_alpha=0.5248, reg_lambda=2.2994)를 정교하게 튜닝하였다. 리프 노드 중심 성장을 채택한 LightGBM은 대규모 데이터의 미세한 변동 패턴을 수렴시키고자 learning_rate=0.1179, 최대 리프 노드 수 num_leaves=45, min_child_samples=72를 도출하여 학습 효율을 극대화하였다. CatBoost 모형 역시 복잡한 범주형 변수 환경에 대응하여 대칭 트리 구조의 깊이를 depth=9, 반복 횟수를 iterations=986, 학습률을 learning_rate=0.0827로 조정하며 일반화 성능을 확보하였다. 최종 단계에서는 이와 같이 최적화된 알고리즘들인 Ridge, Random Forest, LightGBM, CatBoost를 1차 기반 모델(base models)로 설정하고, 이들의 예측치를 메타 러너인 릿지 회귀의 입력으로 활용하는 스택킹 앙상블(Stacking Ensemble) 아키텍처로 개별 알고리즘의 예측 장점이 결합된 최종 가격 예측 파이프라인을 완성하였다.

4.5 Results

본 연구에서 총 11종의 단일 머신러닝 모델과 1개의 스택킹 앙상블(Stacking Ensemble) 모델을 학습시킨 후, 모델의 예측 정확도와 일반화 성능을 검증하였다. 각 모델의 최종 성능 평가 결과는 표 6과 같다.

표 6. 모델별 성능 평가

Model	R^2 Score	MAE(log)	MAE(INR)	RMSE(log)	RMSE(INR)
Multiple Linear Regression	0.8791	0.3030	6707.1	0.3994	14514.7
Lasso	0.8789	0.3033	6642.8	0.3996	14106.1
Ridge	0.8791	0.3030	6706.6	0.3994	14510.9
SVM	0.8687	0.3021	6987.0	0.4161	17390.9
KNN	0.9370	0.1779	4059.0	0.2882	10256.0
Decision Tree	0.9560	0.1243	2987.9	0.2410	9100.5
Random Forest	0.9610	0.1452	3402.9	0.2270	8444.6
Extra Trees	0.6959	0.5523	11647.4	0.6540	19453.8
XGBoost	0.9509	0.1792	3838.1	0.2546	8414.5
LightGBM	0.9540	0.1698	3704.0	0.2462	8298.6
Catboost	0.9580	0.1567	3532.8	0.2352	8268.6
Ensemble Stacking	0.9616	0.1424	3330.2	0.2251	8202.0

실험 결과, 본 연구에서 최종 제안한 스택킹 앙상블(Stacking Ensemble) 모델이 R^2 Score

0.9616, RMSE 8,202.0 루피, MAE 3,330.2 루피를 기록하며 전체 모델 중 가장 우수한 항공편 가격 예측 성능을 입증하였다. 이는 단일 모델 중 가장 우수한 오차 수치를 보인 Random Forest와 비교했을 때도 오차율을 유의미하게 감소시킨 결과임을 확인할 수 있다.

스태킹 앙상블 모델이 기존의 개별 베이스라인 모델들과 차별화되는 구조적 특징 및 성능 향상 원인은 다음과 같다. 첫째, 알고리즘의 다양성(Diversity) 확보를 위한 전략적 모델 조합 및 역할 분담이다. 본 연구에서 선형 회귀 계열, 배깅 계열, 그래디언트 부스팅 계열을 혼합하여 스태킹을 구성한 이유는 단일 알고리즘 군이 가질 수 있는 고유의 예측 편향(Bias)을 상호 보완하기 위함이다. 스태킹 구조 내에서 각 모델은 고유의 메커니즘에 따라 독립적인 역할을 수행한다. 선형 모델인 Ridge는 데이터의 전반적인 거시적 흐름과 선형적 추세를 학습하여 앙상블의 기초적인 예측 방향성을 잡는다. 단일 선형 모델들은 R^2 Score 0.8791 수준의 한계를 보였으나, 기저의 선형적 변동 정보를 제공하여 예측의 급격한 왜곡을 방지한다. 배깅 모델인 Random Forest는 여러 독립적인 결정 트리를 병렬로 학습시켜 데이터의 분산(Variance)을 제어하는 역할을 담당하며 단일 모델로서 R^2 Score 0.9612의 우수한 성능을 보였다. 그래디언트 부스팅 계열인 LightGBM과 CatBoost는 이전 트리의 잔차(Residual)를 연속적으로 보완하는 메커니즘을 통해 데이터 내 복잡한 비선형 패턴과 범주형 변수의 특이성을 정밀하게 학습한다. 스태킹 모델은 이처럼 서로 다른 강점을 가진 알고리즘들의 관점을 결합함으로써, 단일 부스팅 모델이 놓칠 수 있는 오차 패턴을 보완하였다. 둘째, 다중공선성 제어를 통한 안정적인 메타 학습이다. 1단계 개별 베이스라인 모델들이 출력하는 예측값들은 상호 간에 강한 상관관계를 가지므로, 이를 단순 선형 결합할 경우, 다중공선성으로 인한 과적합 위험이 커진다. 그러나 본 연구의 스태킹 모델은 2단계 메타 러너로 Ridge를 채택함으로써, 가중치 왜곡을 줄이고 안정적인 가격 예측을 유도하였다. 결과적으로 전통적인 통계 기반 모델이나 단일 그래디언트 부스팅 모델 알고리즘에 비해, 스태킹 앙상블 알고리즘은 개별 모델들의 예측 오차 패턴을 메타 학습기가 상호 보완하도록 설계됨으로써 비선형적 변동을 단일 알고리즘 대비 정확하게 예측할 수 있음을 확인하였다.

본 연구에서는 개별 특성이 가격 예측에 미치는 직접적인 영향력을 파악하기 위해 단일 알고리즘 중 최고 성능을 기록한 랜덤 포레스트(Random Forest) 알고리즘을 활용하였다. 예측 성능이 가장 우수했던 모형은 스태킹 앙상블(Stacking Ensemble) 모델이었으나, 스태킹 모형은 여러 기반 모델(Base-learner)의 예측값을 다시 메타 러너(Meta-learner)의 입력으로 활용하는 다층 구조를 지니고 있어, 개별 독립변수가 최종 예측 결과에 기여한 정도를 직관적으로 수치화하기 어렵다는 블랙박스(Black Box) 한계를 지닌다. 반면, 랜덤 포레스트(Random Forest)는 독립적인 다수의 의사결정트리들이 예측한 결과를 통합하므로, 최종 예측에 도달하는 과정에서 각 특성이 오차를 줄이는 데 기여한 정도를 명확한 수치로 확인할 수 있다. 따라서 모델의 고도화된 예측 성능은 스태킹 모형을 통해 확보되되, dynamic pricing의 핵심 원인과 인사이트를 도출하기 위한 특성 중요도 분석에는 랜덤 포레스트 모형을 채택하였다. 분석 결과, 좌석 등급(Class) 변수가 가격 변동을 설명하는 가장 압도적인 요인으로 나타났다. 그러나 좌석 등급은 서비스의 질적 차이에 따라 초기 단가 자체가 수 배 이상 차이 나는 특성을 가지고 있음이 자명하므로, 이를 포함한 전체 데이터 분석만으로는 등급별 세부 가격 동향을 면밀히 파악하기 어렵다는 한계가 존재했다. 이에 본 연구에서는 각 시장의 독립적인 가격 결정 요인을 식별하고자 데이터를 이코노미와 비즈니스 클래스로 분리하여 각각 상위 5개의 핵심 변수 중요도를 재추출하였다(그림3). 분석 결과, 이코노미 클

래스 가격 예측 모델에서는 출발까지 남은 일수(days_left, 22.71%)가 가장 중요한 변수로 작용했으며, 운항 시간(duration, 18.58%)과 인도 노선 여부(country_India, 15.01%)가 그 뒤를 이었다. 이는 이코노미 클래스 소비자의 경우 예약을 진행하는 시점, 즉 구매의 시급성에 따라 가격 탄력성이 매우 민감하게 변동하는 시장 특성을 반영한다. 반면 비즈니스 클래스 모델에서는 운항 시간(duration)의 중요도가 42.87%로 고정되어 압도적인 영향력을 행사했으며, 경유 횟수(stops, 23.70%)가 두 번째로 높은 비중을 차지했지만, 출발 잔여일(days_left, 2.31%)의 영향력은 미미한 것으로 확인되었다. 이러한 결과는 비즈니스 클래스의 주요 소비층이 예약 시점보다는 장거리 비행이나 경유 여부와 같은 운항의 물리적 조건 및 편의성에 가치를 두고 의사결정을 한다는 점을 시사한다.




그림 3. Random Forest의 클래스별 특성 중요도

5. Limitations

5.1 잠재적 한계점

본 연구에서 제안한 머신러닝 기반 가격 예측 방법론은 시험 데이터셋에서 우수한 오차 감소 효과를 증명하였으나 몇 가지 잠재적인 한계점을 지닌다. 우선 인도와 방글라데시라는 특정 국가 및 항공 시장의 데이터만을 통합하여 학습을 수행했기 때문에, 국가별 경제 상황이나 환율, 항공 정책이 상이한 글로벌 항공 시장에서도 동일한 성능을 보장한다고 보기 어렵다. 즉, 사용된 데이터 세트의 지리적 환경에 모델이 과적합되어 타 국가의 시장에 일반화하여 적용하기에는 한계가 존재할 수 있다. 또한 개별 부스팅 모델 및 비선형 모델들을 선행 학습시킨 후 메타데이터 생성을 위해 교차 검증을 수행하는 스택킹 앙상블 구조는 단일 모델을 독립적으로 운용할 때보다 대량의 연산 비용과 긴 학습 및 추론 시간을 요구한다. 특히 데이터 규모가 확장될수록 학습 속도가 저하되는 등 학습 안정성 측면의 제한점이 명확하게 나타났다.

5.2 실험 설계상의 제약 사항

본 연구의 실험을 설계하고 진행하는 과정에서는 컴퓨팅 자원 및 데이터 전처리 구조로 인한 제약사항이 발생하였다. 스택킹 앙상블의 평가 신뢰도를 높이기 위해 초기 설계 단계에서는 5-fold 교차 검증으로 학습을 시도하였으나, 제한된 컴퓨팅 자원 환경에서 대규모 하이퍼파라미터 탐색과 다수의 앙상블 모델 학습을 동시에 수행함에 따라 과도한 시간과 연산 비용이 소요되는 문제가 발생하였다. 이에 따라 실험의 효율성과 시간적 제약을 고려하여 교차 검증 폴드 수를 3-fold로 하향 조정하여 최종 실험을 수행하게 되었다. 이로 인해 모델을 보다 엄격하게 검증하는 데 일부 제약이 있었을 가능성이 존재한다. 이와 더불어 데이터 전처리 과정에서 항공사, 노선, 국가 등 고유 값이 많은 범주형 변수에 원-핫 인코딩을 적용함에 따라 데이터의 차원이 급격히 상승하였다. 이는 메모리 사용량 증가와 모델 복잡도 상승으로 이어졌으며, 결과적으로 다양한 변수 조합 및 모델 구성 요소를 독립적으로 검증하는 충분한 어블레이션 스터디(ablation study)를 수행하는 데 제약이 되었다.

5.3 특정 환경에서의 성능 저하 및 취약 상황

제안한 방법론은 안정적인 시장 상황을 가정한 실험에서는 유효성을 보였으나, 특정 환경 및 실무 운용 시나리오에서는 효과적이지 않을 수 있다. 제안된 파이프라인은 여러 고차원 모델을 순차적으로 거쳐 최종 예측치를 출력하는 구조를 가지므로, 수요에 따라 초 단위로 가격이 변동하는 실시간 dynamic pricing 시스템 내에 탑재될 경우, 자원 제약 및 지연 문제가 발생하여 시스템 효율성이 저하될 수 있다. 아울러 본 연구는 항공권 내부 데이터만을 피쳐로 사용했기 때문에 실시간 국제 유가 폭등, 환율 급변, 팬데믹 등의 거시경제적 변수나 돌발적인 시장 충격이 발생하는 상황에는 취약하다. 이처럼 데이터의 분포 자체가 급격히 변하는 환경이나 인도와 방글라데시의 항공권 소비 패턴과 다른 소비 패턴을 보일 경우, 모델의 예측력이 저하되어 일시적으로 큰 예측 오차가 발생할 가능성이 있다.

5.4 한계점 개선 및 향후 연구 방향

위에서 논의한 한계와 제약을 극복하기 위해 향후 연구에서는 다음과 같은 방향으로 모델을 고도화하고자 한다. 먼저 다양한 국가 및 글로벌 항공사의 방대한 데이터셋을 추가로 확보하여 일반화 성능을 검증하는 동시에, 유가, 환율, 공휴일 등의 외부 경제 지표를 정형 데이터 파이프라인에 동적으로 연동하여 시장 변동성 대응력을 강화할 필요가 있다. 이와 함께 고성능 컴퓨팅 자원을 확보하여 초기 설계 단계에서 제한되었던 5-fold 이상의 교차 검증을 수행함으로써 모델 평가의 신뢰도를 한층 더 높이하고자 한다. 또한 스택킹 메타 러너의 가중치 분석을 통해 기여도가 낮은 베이스라인 모델을 제외하거나 트리의 깊이를 최적화함으로써 연산 비용을 절감하고, 실시간 추론 환경에 적합하도록 모델 구조를 경량화한다. 마지막으로, 항공권 시장의 고유한 비즈니스 규칙과 실무적 요구사항을 모델에 반영하여 예측의 실효성을 높이는 것이 필요하다. 일반적인 머신러닝 모델은 데이터의 노이즈로 인해 출발 예정일이 임박했을 때 오히려 가격이 하락하는 등 상식에 어긋나는 예측 역전 현상을 보일 수 있다. 이를 방지하기 위해 구매 시점이 가까워질수록 가격이 상승하는 항공 도메인의 특성을 고려하여, 모델의 출력값이 시간에 따라 하락하지 않도록 수학적 단조성 제약(Monotonicity Constraints)을 도입해야 한다. 이와 함께, 저가 좌석과 고가 좌석에서 발생하는 동일한 액수의 오차가 실무에 미치는 파급력이 서로 다르다는 점을 통계적으로 보완하고자 한다. 실제 가격 대비 오차의 비율을 고려하여 가격이 높은 좌석을 잘못 예측했을 때 모델에

더 큰 페널티를 부여하는 비대칭 오차 함수(Asymmetric Loss Function)를 결합하는 시도가 필요하다. 이와 같은 방식으로 연구를 확장하여 개선해 나간다면, 단순히 통계적 지표만 높은 모델을 넘어 예측의 안정성을 확보한 더 좋은 모델이 될 수 있으며, 나아가 실제 항공 dynamic pricing 비즈니스 환경에서도 실질적으로 사용될 가능성이 높아질 것으로 기대된다.

6. Conclusion

6.1 연구의 목표와 접근 방법 요약

본 연구는 항공권 가격 데이터의 변동 패턴을 예측하고, 가격 결정에 미치는 핵심 요인을 정량적으로 규명하여 예측 정확도와 설명력을 동시에 확보하는 것을 목표로 진행되었다. 이를 위해 먼저 항공권 운임 특유의 우측 비대칭 분포를 로그 변환으로 정규화하고, 출발 전 남은 일수를 범주화한 '예약 기간' 변수를 생성하여 시계열적 맥락을 반영하는 특성 공학을 수행하였다. 모델링 단계에서는 단일 모형의 예측 편향을 극복하고자 Random Forest, Ridge, LightGBM, CatBoost를 기반 모델로 삼고, Ridge를 메타 러너로 취합하는 스택킹 앙상블을 구축하여 단일 모델 대비 우수한 예측 성능을 보였다. 또한 단일 모델 중 가장 우수한 성능을 보인 Random Forest에서 특성 중요도를 추출하고, 데이터를 이코노미와 비즈니스 클래스로 분리하여 각 세부 요인의 영향력을 심층 비교 분석하는 차별화된 접근 방법을 제시하였다.

6.2 연구를 통해 기대되는 성과

본 연구는 알고리즘의 결합을 통한 기술적 고도화와 데이터 기반의 심층 분석을 동시에 달성함으로써 학술 및 실무 전반에 걸쳐 유의미한 성과를 기대할 수 있다. 우선 기술적 측면에서는 서로 다른 작동 메커니즘을 가진 알고리즘들을 최적으로 결합한 스택킹 앙상블 체계를 구축하여, 기존 단일 머신러닝 모형이 가지는 예측 편향을 상쇄했다. 특히 예측 오차율을 낮춰 변동성이 극심한 항공권 운임 예측 분야에서 다중 모델 앙상블의 기술적 타당성과 외연을 확장하는 계기를 마련한다. 이와 같은 예측력을 바탕으로, 고성능 블랙박스(Black-box) 모델의 한계로 지적되는 설명력 부족 문제를 극복하고 실무적 인사이트를 제공한다는 점 역시 중요한 성과이다. 단순히 특성 중요도에 머무르지 않고, 가격 결정의 핵심 변수인 '클래스'를 기준으로 데이터를 분리하여 검증하는 차별화된 분석 구조를 통해 각 클래스별 운임 결정 요인을 규명하였다. 이는 단순히 가격을 예측하는 기존 연구를 넘어, 시장의 구조적 특성을 데이터 기반(Data-Driven)으로 명확히 시각화하고 비즈니스 인사이트를 부여했다는 점에서 높은 평가를 기대할 수 있다.

6.3 Future work 및 활용 가능성

본 연구에서 제안한 방법론과 분석 결과는 향후 실제 비즈니스 시스템에 직접 반영되어 높은 실무적 가치를 창출할 수 있다. 구체적으로는 개발된 스택킹 예측 모델을 API 형태의 서비스로 배포하여, 소비자에게는 비용 절감을 위한 '최적의 구매 윈도우(Optimal Buying Window)'를 안내하는 추천 엔진으로 활용할 수 있다. 이와 동시에 공급자인 항공사 및 온라인 여행사(OTA)에는 데이터 기반의 정교한 동적 운임(Dynamic Pricing) 최적화 시스템의 핵심 알고리즘으로 적용함으로써 수익 관리(Yield Management) 효율성을 극대화할 수 있을 것이다. 나아가 추가적인 데이터 세트 확장을 도모한다면, 단일 정형 데이터에 기반한 예측을 넘어 복잡한 현실 세계의 변동성을 정확히

게 파악하는 시스템으로 발전할 수 있다. 실제 항공권 가격은 유가 변동률, 글로벌 인플레이션 지표, 휴일 및 계절적 성수기 요인 등 거시 경제 및 외부 환경 변수에 의해 끊임없이 변화한다. 비록 이러한 외생 변수들은 예측이 까다롭고 시점별로 영향력이 달라지지만, 후속 연구를 통해 각 핵심 변수의 영향력을 정량화해 나간다면 외부 충격과 민감한 시장 변화에도 흔들리지 않는 강건한 모델을 확보할 수 있다. 마지막으로, 모델의 아키텍처 측면에서 시계열 특화 하이브리드 구조를 채택한다면 특정 기간에 발생하는 고질적인 오차를 크게 감소시킬 수 있다. 현재 구축된 트리 기반 모델 중심의 스택킹 구조에서 한 단계 나아가, LSTM이나 GRU 같은 순환 신경망(RNN) 계열 알고리즘 또는 Prophet과 같은 통계적 시계열 모델을 베이스 러너(Base Learner)로 추가 결합하는 방식이다. 이처럼 시계열 특화 모델을 앙상블에 융합함으로써 항공권 가격의 계절적 주기성과 장기 트렌드 정보를 보완한다면, 수요가 급증하는 성수기나 연휴 기간의 예측 오차를 획기적으로 줄이고 전반적인 모델의 신뢰도를 완성할 수 있을 것이다.

참고문헌(Reference)

- [1] T. Kalampokas et al., "A Holistic Approach on Airfare Price Prediction Using Machine Learning Techniques," *IEEE Access*, vol. 11, 2023. doi: 10.1109/ACCESS.2023.3274669
- [2] T. Deng, "International flight fare prediction and analysis of factors impacting flight fare," *Theoretical and Natural Science*, vol. 31, no. 1, pp. 329-335, 2024.
- [3] M. Erturk et al., "Large-scale airline ticket price prediction using ensemble learning," *DergiPark*, 2025.
- [4] H. Korkmaz, "Prediction of airline ticket price using machine learning method," *Journal of Transportation and Logistics*, vol. 9, no. 2, pp. 205-218, 2024. doi: 10.26650/JTL.2024.1486696.
- [5] A. Chavan, I. Rathod, and S. Bobde, "Comparative Analysis of Machine Learning Models for Accurate Flight Price Prediction," *IJISRT*, vol. 9, no. 9, pp. 2798-2804, 2024.
- [6] A. P. Reddy, A. Tarafdar, and U. K. Bera, "Regression based Machine Learning approach to predict Flight Price between Bangalore and Kolkata," in *Proc. IEEE 8th International Conference for Convergence in Technology (I2CT)*, pp. 1-6, 2023. doi: 10.1109/I2CT57861.2023.10126456.
- [7] W. A. Degife and B.-S. Lin, "Deep-Learning-Powered GRU Model for Flight Ticket Fare Forecasting," *Applied Sciences*, vol. 13, no. 10, p. 6032, 2023. doi: 10.3390/app13106032.
- [8] P. Wong et al., "Using Spark Machine Learning Models to Perform Predictive Analysis on Flight Ticket Pricing Data," *arXiv*, arXiv:2310.07787, 2023. doi: 10.48550/arXiv.2310.07787.
- [9] A. Asukar and S. Londhe, "Forecasting Airline Ticket Prices: A Comparative Study of Time Series Models with Seasonal Trends," *IJARST*, vol. 5, no. 1, pp. 19-29, 2025. doi: 10.48175/IJARST-26105.
- [10] Dhanush, P. Satwik, Sandeep, and A. R. P. Reddy, "Flight Price Prediction Using

Machine Learning and Deep Learning: A Comparative Study," IRE Journals, vol. 9, no. 11, pp. 115-121, 2026. doi: 10.64388/IREV9I11-1717258.

[11] H. Yu, "Predict Airline Ticket Prices Based on Machine Learning Models," in Proc. 2025 2nd International Conference on Digital Economy, Blockchain and Artificial Intelligence (DEBAI 2025), Beijing, China, Jun. 2025, pp. 83-88. doi: 10.1145/3762249.3762264.